МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное
образовательное учреждение высшего образования
Национальный исследовательский Нижегородский государственный университет
им. Н.И. Лобачевского

Институт информационных технологий, математики и механики

Направление подготовки
Фундаментальная информатика и информационные технологии

Направленность образовательной программы
магистерская программа «Компьютерная графика и моделирование живых и технических систем»

Образовательный курс: «Анализ производительности и оптимизации ПО»

Отчет по лабораторной работе

Промахи кэша

Выполнил(а): студент(ка) группы 381706-3м
_____Е.С.Зубарева
Подпись

Н. Новгород
2019

Задача: L3 cache miss -> L3 cache hit

Характеристики компьютера:

Операционная система: Windows 7

Процессор: Intel Core i5 – 62004 2.30 GHz

L1 – 128 Кб, L2 – 512 Кб, L3- 3072 Кб

Оперативная память – 4 Гб

Описание проблемы

Кэш ЦП - это аппаратный кэш, используемый центральным процессором (ЦП) компьютера для снижения средней стоимости (времени или энергии) доступа к данным из основной памяти. Кэш-это меньшая, более быстрая память, ближе к ядру процессора, который хранит копии данных из часто используемых основных расположений памяти . По сути кэш-память выполняет роль быстродействующего буфера памяти хранящего информацию, которая может потребоваться процессору. Таким образом процессор получает необходимые данные в десятки раз быстрее, чем при считывании их из оперативной памяти.

Кэш память выполнена в виде микросхем статической оперативной памяти (SRAM), которые устанавливаются на системной плате либо встроены в процессор. В сравнении с другими видами памяти, статическая память способна работать на очень больших скоростях. Скорость кэша зависит от объема конкретной микросхемы. Самой распространенной на сегодняшний день считается трехуровневая система кэша L1,L2, L3:

L1 — самая маленькая по объему (всего несколько десятков килобайт), но самая быстрая по скорости и наиболее важная. Она содержит данные наиболее часто используемые процессором и работает без задержек. Обычно количество микросхем памяти уровня L1 равно количеству ядер процессора, при этом каждое ядро получает доступ только к своей микросхеме L1.

L2 по скорости уступает памяти L1, но выигрывает в объеме, который измеряется уже в нескольких сотнях килобайт. Она предназначена для временного хранения важной информации, вероятность обращения к которой ниже, чем у информации хранящейся в L1.

L3 — имеет самый большой объем из трех уровней (может достигать десятков мегабайт), но и обладает самой медленной скоростью. Кэш память L3 служит общей для всех ядер процессора. L3 предназначен для временного хранения тех важных данных, вероятность обращения к которым чуть ниже, чем у информации которая хранится в первых двух уровнях. Она также обеспечивает взаимодействие ядер процессора между собой.

Cache miss (кэш-промах) и Cache hit (кэш-попадание)

В процессе работы отдельные блоки информации копируются из основной памяти в кэш-память. При обращении процессора за командой или данными сначала проверяется их наличие в кэш-памяти. Если необходимая информация находится в кэше, она быстро извлекается. Это кэш-попадание. Если необходимая информация в кэш-памяти отсутствует (кэш-промах), то она выбирается из основной памяти, передается в микропроцессор и одновременно заносится в кэш-память. Повышение быстродействия вычислительной системы достигается в том случае, когда кэш-попадания реализуются намного чаще, чем кэш-промахи.

Описание решаемой задачи

Проведем анализ простого классического алгоритма умножения матриц большой размерности (1000*1000), заполненных рандомными положительными числами от 1до 100.

Обнаружение и решение проблемы

Для анализа используем Intel® VTune™ Amplifier XE 2019.

Intel® VTune™ Amplifier XE – профилировщик для оптимизации производительности и масштабируемости. Помогает за короткое время обнаружить проблемы производительности и причины плохой масштабируемости приложений на многоядерных системах.

Запустим Memory Access Tools:

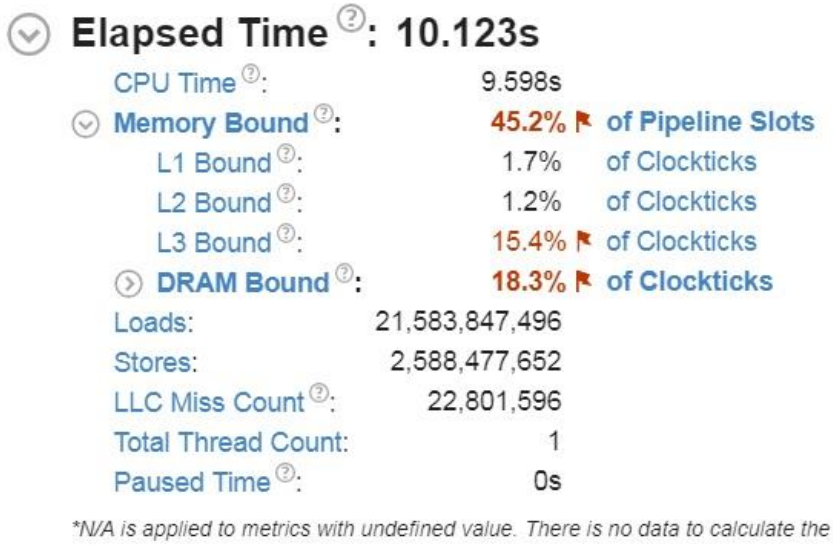

Время работы алгоритма: 10.123s.

Видим проблемы в значениях Memory Bound, а именно в кэш-памяти L3 и основной памятью (DRAM Bound). Посмотрим в каком месте кода обнаружена проблема:

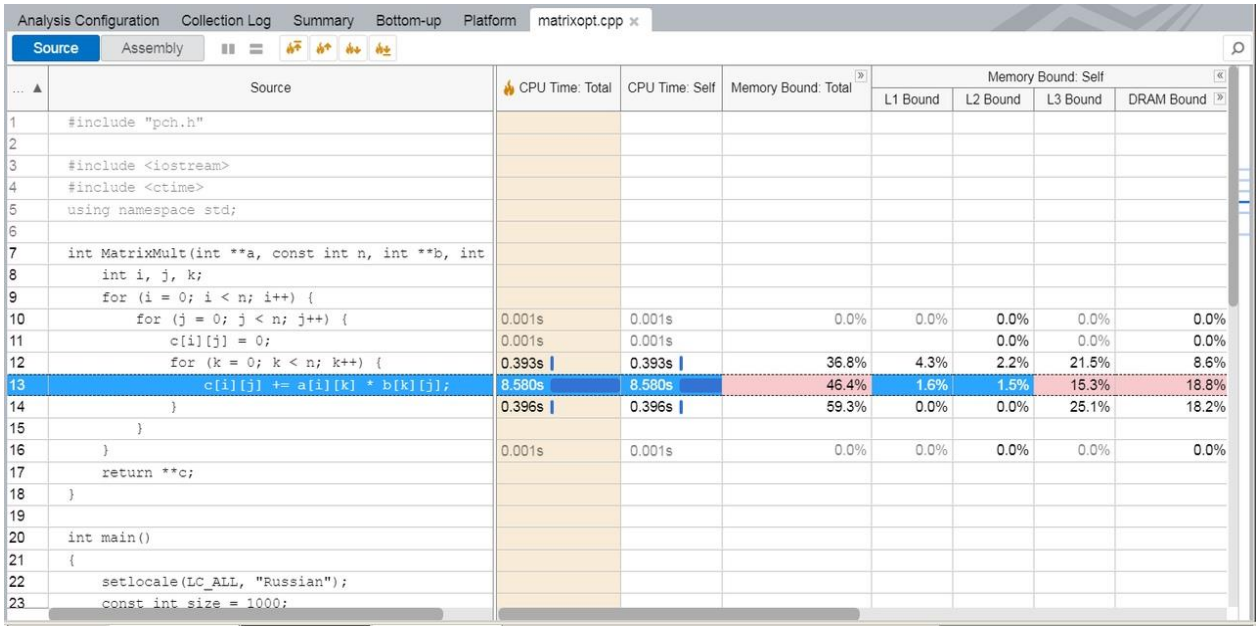

	Source	CPU Time: Total	CPU Time: Self	Memory Bound: Total	Memory Bound: Self			
					L1 Bound	L2 Bound	L3 Bound	DRAM Bound
1	#include "pch.h"							
2								
3	#include <iostream>							
4	#include <ctime>							
5	using namespace std;							
6								
7	int MatrixMult(int **a, const int n, int **b, int							
8	int i, j, k;							
9	for (i = 0; i < n; i++) {							
10	for (j = 0; j < n; j++) {	0.001s	0.001s	0.0%	0.0%	0.0%	0.0%	0.0%
11	c[i][j] = 0;	0.001s	0.001s			0.0%	0.0%	0.0%
12	for (k = 0; k < n; k++) {	0.393s	0.393s	36.8%	4.3%	2.2%	21.5%	8.6%
13	c[i][j] += a[i][k] * b[k][j];	8.580s	8.580s	46.4%	1.6%	1.5%	15.3%	18.8%
14	}	0.396s	0.396s	59.3%	0.0%	0.0%	25.1%	18.2%
15	}							
16	}	0.001s	0.001s	0.0%	0.0%	0.0%	0.0%	0.0%
17	return **c;							
18	}							
19								
20	int main()							
21	{							
22	setlocale(LC_ALL, "Russian");							
23	const int size = 1000;							

Видим, что это как цикл функции MatrixMult:

```
int MatrixMult(int **a, const int n, int **b, int **c) {
    for (int i = 0; i < n; i++) {
        for (int j = 0; j < n; j++) {
            c[i][j] = 0;
            for (int k = 0; k < n; k++) {
                c[i][j] += a[i][k] * b[k][j];
            }
        }
    }
    return 0;
```

В реализации алгоритма умножения матриц порядок циклов (соответствующий определению):

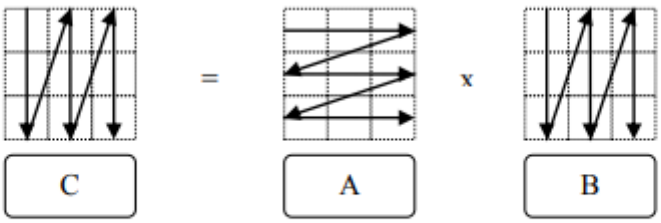

Обход матриц в реализации умножения по определению

Учитывая, что матрицы хранятся непрерывным вектором, обход матриц B и C не оптимален (хоть и имеет регулярный характер). Значительную роль в снижение производительности играет обход матрицы B. Элементы матрицы B используются n^3 раз, а матрицы C – n^2 раз. Что бы оптимизировать код, нужно сделать порядок обхода матриц последовательным. Транспонируем матрицу B:

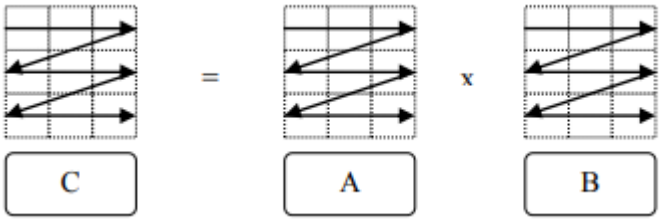

Как следствие, повысилась производительность. Запустим Vtune Memory Access и проведем анализ:

Elapsed Time: 4.931s

CPU Time:	4.631s	
Memory Bound:	**1.0%**	**of Pipeline Slots**
L1 Bound:	0.9%	of Clockticks
L2 Bound:	0.0%	of Clockticks
L3 Bound:	0.7%	of Clockticks
DRAM Bound:	**0.0%**	**of Clockticks**
Loads:	22,302,669,060	
Stores:	1,818,054,540	
LLC Miss Count:	0	
Total Thread Count:	1	
Paused Time:	0s	

**N/A is applied to metrics with undefined value. There is no data to calculate the metric.*

Результаты

Был проведен анализ алгоритма умножения матриц в профилировщике в Intel® VTune™ Amplifier XE. Проведены анализ и оптимизация работы с памятью.

Современные процессоры чувствительны к тому, в каком порядке происходит чтение и запись в память. Если чтение и запись происходит последовательно, то процессор может это предсказать и заранее загрузить данные в кэш-память. Доступ к кэш-памяти гораздо быстрее доступа к оперативной памяти. Кроме того, данные в кэш-память загружаются не поэлементно, а сразу группами.

Низкая производительность алгоритма была из-за неудачно организованной работы с памятью. Проведена оптимизация, изменен порядок обхода матриц на последовательный. Таким образом, была увеличена производительность и время работы больше чем в 2 раза.

Приложение

```
#include <iostream>
#include <ctime>
using namespace std;

int MatrixMult(int **a, const int n, int **b, int **c) {
	int **bT = new int *[n];
	for (int i = 0; i < n; i++) bT[i] = new int[n];
	for (int i = 0; i < n; i++) {
		for (int j = 0; j < n; j++) {
			bT[i][j] = b[j][i];
		}
	}
	for (int i = 0; i < n; i++) {
		for (int j = 0; j < n; j++) {
			c[i][j] = 0;
			for (int k = 0; k < n; k++) {
				c[i][j] += a[i][k] * bT[j][k];
			}//cout << c[i][j] << " ";
		}//cout << "\n";
	}
		return 0;
}

int main()
{
	setlocale(LC_ALL, "Russian");
	const int size = 1000;
	int **A=new int *[size];
	for (int i = 0; i < size; i++) A[i] = new int [size];
	int **B = new int *[size];
	for (int i = 0; i < size; i++) B[i] = new int[size];
	int **C = new int *[size];
	for (int i = 0; i < size; i++) C[i] = new int[size];
	srand(time(NULL));
	for (int i = 0; i < size; i++) {
		for (int j = 0; j < size; j++) {
			A[i][j] = rand() % 100 + 1;
			//cout << A[i][j] << " ";
		}//cout << "\n";
	}
	for (int i = 0; i < size; i++) {
		for (int j = 0; j < size; j++) {
			B[i][j] = rand() % 100 + 1;
			//cout << B[i][j] << " ";
		}//cout << "\n";
	}

	MatrixMult(A, size, B, C);

	delete []A;
	delete[]B;
	delete[]C;
	return 0;
}
```